

재무비율 기반 분식회계 확률 예측 모델

모델 설계 및 노트북 항목별 설명 보고서

본 보고서는 AICE-Associate 자격 과정에서 학습한 데이터 분석 및 머신러닝 기법을 실제 회계 데이터에 적용하여, 감사대상회사의 재무비율을 입력하면 분식회계 확률을 자동으로 산출하는 예측 모델을 개발한 과정과 그 결과를 정리한 것입니다.

1. 프로젝트 개요

1-1. 목표

감사대상회사의 재무정보를 입력하면, 여러 재무비율을 자동으로 계산하여 해당 회사가 분식회계(회계처리 기준 위반)를 했을 확률(%)을 출력하는 머신러닝·딥러닝 모델을 개발한다.

1-2. 전체 프로세스

단계	내용	산출물
1. 라벨 데이터 구축	금융위원회 증권선물위원회 보도자료에서 실명이 확인된 분식회계 확정 기업 수집	fraud_labels.csv (18개사)
2. 재무데이터 수집	DART Open API로 분식기업·정상기업의 실제 재무제표(당기/전기) 조회	beneish_scores.csv, control_scores.csv
3. 재무비율 계산	Beneish M-Score의 8개 지표(DSRI, GMI, AQI, SGI, DEPI, SGAI, LVGI, TATA) 산출	8개 재무비율 컬럼
4. 데이터 고정	분식 11개 + 정상 76개, 총 87개사 데이터를 하나의 학습용 파일로 고정	training_data_final.csv
5. 모델 학습	이상치 처리 → 스케일링 → 훈련/검증 분리 → 머신러닝(로지스틱 회귀) → 딥러닝 순으로 모델 학습	학습된 예측 모델
6. 실전 적용	새 회사의 corp_code+연도 입력 → DART 자동조회 → 비율계산 → 확률출력	분식 확률(%)

1-3. 최종 데이터 구성

구분	표본 수	비고
분식기업 (label=1)	11개사	검찰고발, 대표이사 해임권고 등 확정 조치 사례
정상기업 (label=0)	76개사	중소형 상장사 49개 + 대기업 27개(추가 보강)
합계	87개사	training_data_final.csv

2. 사용된 재무비율 (Beneish M-Score 8개 지표)

본 모델은 회계학자 Messod Beneish가 1999년 제안한 분식회계 탐지 지표 8개를 피처(feature)로 사용합니다. 각 지표는 당기와 전기 재무제표를 비교하여 계산됩니다.

지표	명칭	의미	값이 클수록
DSRI	매출채권 지수	매출채권/매출액 비율의 전기 대비 변화	가공매출 의심
GMI	매출총이익률 지수	전기 매출총이익률 / 당기 매출총이익률	수익성 악화 은폐 의심
AQI	자산의 질 지수	비유동·비상각성 자산 비중의 변화	자산 부풀리기 의심
SGI	매출성장률 지수	당기매출 / 전기매출	급격한 성장 → 압박 심화
DEPI	감가상각률 지수	감가상각 속도의 변화	이익 부풀리기 의심
SGAI	판관비율 지수	판매비와관리비/매출액 비율의 변화	비효율/이상 신호
LVGI	레버리지 지수	부채비율(부채/자산)의 변화	재무구조 악화, 분식 유인 증가
TATA	총발생액 비율	(운전자본 변화-감가상각비)/총자산	실제 현금흐름과 괴리, 이익조정 의심

참고로 원래 Beneish M-Score는 위 8개 지표에 고정된 가중치를 곱해 하나의 점수(M)를 산출하고, -1.78이라는 고정 임계값으로 위험 여부를 판정하는 방식입니다. 그러나 이 고정 공식은 1999년 미국 GAAP/Compustat 데이터를 기반으로 만들어져, 국내 K-IFRS 데이터에 그대로 적용할 경우 탐지력이 떨어지는 한계가 확인되었습니다. 이에 본 프로젝트에서는 8개 지표는 그대로 활용하되, 가중치는 고정 하지 않고 실제 국내 분식·정상 기업 데이터로 직접 재학습하는 방식(머신러닝·딥러닝)을 택했습니다.

3. 노트북 항목별 상세 설명

(fraud_prediction_model.ipynb 기준)

1. 라이브러리 불러오기

pandas(데이터 처리), sklearn(전처리·머신러닝·평가), tensorflow.keras(딥러닝 모델)을 불러옵니다. tf.random.set_seed(1)은 모델 학습 결과가 실행할 때마다 달라지지 않도록 난수를 고정하는 역할입니다.

2. 데이터 불러오기

고정된 학습 데이터(training_data_final.csv)를 pandas 데이터프레임으로 읽어옵니다. 이 파일 하나에 분식기업 11개, 정상기업 76개의 재무비율과 정답(label)이 모두 들어있습니다.

3. 데이터 분석 (라벨 분포 확인)

seaborn의 countplot으로 정상(0)기업과 분식(1)기업의 개수를 시각적으로 비교합니다. 두 클래스의 개수 차이가 큰 것을 "클래스 불균형"이라 하며, 이는 이후 모델 학습 시 보정이 필요한 부분입니다.

4. 이상치 처리

각 재무비율 지표의 상위 1%, 하위 1%에 해당하는 극단값을 해당 경계값으로 눌러주는 클리핑(clipping)을 적용합니다. 행을 삭제하는 대신 값만 보정하므로 표본이 적은 상황에서 데이터 손실을 최소화할 수 있습니다.

5. 결측치 확인

8개 재무비율 컬럼에 비어있는(NaN) 값이 있는지 최종 점검합니다.

6. 훈련/검증 데이터셋 분리

전체 87개사 데이터를 80%(훈련용)와 20%(검증용)로 무작위 분리합니다. stratify=y 옵션으로 분식/정상 비율이 훈련·검증 세트에 고르게 유지되도록 했습니다.

7. 스케일링 (RobustScaler)

8개 지표는 값의 범위가 서로 달라, 그대로 학습하면 값의 범위가 큰 지표가 부당하게 큰 영향력을 갖게 됩니다. RobustScaler는 평균/표준편차 대신 중앙값과 IQR을 기준으로 값을 조정해, 이상치의 영향을 적게 받으면서 모든 지표를 비슷한 스케일로 맞춰줍니다.

8. 머신러닝 모델 학습 (로지스틱 회귀)

딥러닝 모델에 앞서, 비교 기준이 되는 머신러닝 모델을 먼저 학습시킵니다. sklearn의 LogisticRegression을 사용했으며, 분식기업 수가 정상기업보다 훨씬 적으므로 class_weight='balanced' 옵션으로 클래스 불균형을 자동 보정했습니다. 학습 후 accuracy_score, f1_score로 성능을 확인합니다.

9. 딥러닝 모델 구성

Keras의 Sequential 모델로 은닉층 2개(32-16 유닛)를 가진 신경망을 구성했습니다. 은닉층 활성화 함수는 relu, 출력층은 sigmoid를 사용해 0~1 사이의 확률값이 나오도록 했습니다. Dropout(0.2)은 과적합을 방지하는 장치이며, EarlyStopping은 검증 손실이 9번의 epoch 동안 개선되지 않으면 학습을 자동으로 중단시킵니다. 로지스틱 회귀와 마찬가지로 class_weight를 적용하되, 원래 비율을 그대로 적용하면 오탐이 과도해지는 것을 확인하여 강도를 절반(WEIGHT_STRENGTH=0.5)으로 완화했습니다.

10. 학습 곡선 시각화

epoch이 늘어남에 따라 훈련 손실(loss)과 검증 손실(val_loss), 정확도(accuracy)가 어떻게 변하는지 그래프로 확인합니다.

11. 모델 성능 평가

검증 데이터로 예측한 결과를 accuracy_score, f1_score로 평가하고, 8단계에서 학습시킨 로지스틱 회귀 모델과 딥러닝 모델의 성능을 나란히 비교하여 출력합니다.

12. 새 감사대상회사 재무제표 자동 조회 → 비율 계산 → 확률 예측

이 모델의 실전 활용 단계입니다. 감사대상회사의 DART corp_code와 회계연도만 입력하면 DART Open API를 통해 해당 회사의 실제 재무제표(당기·전기)를 자동으로 조회하고, 그 원본 데이터로부터 8개 Beneish 지표를 자동 계산합니다. 계산된 지표를 학습 때 사용한 것과 동일한 RobustScaler로 변환한 뒤, 학습된 딥러닝 모델에 입력하여 최종적으로 분식회계 확률(%)을 출력합니다.

4. 모델 결과 및 해석

4-1. 성능 지표

지표	결과값	의미
표본 수	87개 (분식 11 / 정상 76)	정상기업 표본을 확장하여 안정성 확보
로지스틱 회귀	비교 기준 모델로 우선 학습	딥러닝과의 성능 비교 기준선 확보
딥러닝(최종 모델)	클래스 가중치 적용 후 성능 개선	재현율(분식 탐지)과 정밀도의 균형 확보

4-2. 실전 테스트 사례

회사	실제 상태	비고
삼성전자, 현대자동차, 빙그레	정상(우량·중견기업)	학습 데이터 미포함, 낮은 확률로 판정
SOOP (구 아프리카TV)	분식회계 확정 (2025년 증선위 조치)	학습 데이터 미포함, 정상기업 대비 높은 확률로 판정
SK하이닉스	정상(우량기업)	2022년 반도체 업황 급락기 반영, 판정이 불안정했던 사례

명확히 건전한 기업(삼성전자, 현대차, 빙그레)은 대체로 낮은 확률로 판정되었고, 확정 분식기업(SOOP)은 이보다 높은 확률로 산출되어 방향성 있는 변별력을 확인했습니다. 다만 SK하이닉스처럼 업황이 급격히 나빠진 시기의 우량기업에 대해서는 판단이 불안정한 한계가 있었으며, 이는 별도의 개선 작업(업종 평균 대비 상대지표 적용)으로 이어졌습니다. 자세한 개선 내용은 v2_industry_adjustment 폴더의 별도 보고서를 참고해 주세요.

4-3. 한계점

- 표본 크기: 분식기업 표본이 11개로 적어, 통계적 일반화에는 한계가 있습니다.
- 데이터 접근성: 카카오모빌리티 등 일부 확정 분식기업은 비상장 또는 사업보고서 미제출 대상이라 DART API로 재무데이터를 확보하지 못해 최종 표본에서 제외되었습니다.
- 감가상각비 결측: 국내 재무제표 공시 특성상 감가상각비가 현금흐름표에만 기재되는 경우가 많아, 일부 기업은 DEPI 지표를 중립값(1.0)으로 대체하여 계산했습니다.
- 인과관계 아님: 본 모델은 상관관계 기반의 통계적 예측이며, 특정 재무비율이 분식을 유발한다는 인과관계를 증명하는 것은 아닙니다.
- 재현성: 딥러닝 모델 특성상 실행할 때마다 결과가 소폭 달라지는 문제가 있어, 커널을 완전히 재시작하여 노트북을 처음부터 순서대로 실행하는 방식으로 일관성을 확보하고 있습니다.

4-4. 향후 개선 방향

- 분식기업 및 정상기업 표본을 지속적으로 확대하여 통계적 신뢰도를 높인다.
- 산업군, 기업 규모 등을 통제 변수로 추가하여 비교집단의 정합성을 높인다.
- 로지스틱 회귀, 딥러닝 외에 랜덤포레스트, XGBoost 등 다른 모델과 성능을 비교한다.
- 국내 데이터에 맞는 임계값(threshold) 재보정을 통해 실무 적용 가능성을 높인다.

5. 한 줄 요약

본 프로젝트는 국내 확정 분식회계 기업 11개사와 정상기업 76개사의 실제 재무제표 데이터를 DART Open API로 직접 수집하고, Beneish M-Score의 8개 재무비율을 계산한 뒤, 로지스틱 회귀와 딥러닝 모델을 순차적으로 학습시켜 "감사대상회사의 재무정보를 입력하면 분식회계 확률을 출력하는" 예측 모델을 구현한 것입니다. 표본 크기의 한계를 인지한 상태에서 실무적 시사점을 도출했으며, 실전 검증 과정에서 발견한 한계(SK하이닉스 사례)는 후속 개선 작업으로 이어졌습니다.

본 보고서는 AICE-Associate 학습 내용을 실전 회계 데이터 분석에 적용해본 개인 프로젝트 기록입니다.