

# 재무비율 기반 분식회계 확률 예측 모델

모델 설계 및 노트북 항목별 설명 보고서

본 보고서는 AICE - Associate 자격 과정에서 학습한 데이터 분석 및 머신러닝 기법을 실제 회계 데이터에 적용하여, 감사대상회사의 재무비율을 입력하면 분식회계 확률을 자동으로 산출하는 예측 모델을 개발한 과정과 그 결과를 정리한 것입니다.

# 1. 프로젝트 개요

## 1-1. 목표

감사대상회사의 재무정보를 입력하면, 여러 재무비율을 자동으로 계산하여 해당 회사가 분식회계(회계처리기준 위반)를 했을 확률(%)을 출력하는 머신러닝 모델을 개발한다.

## 1-2. 전체 프로세스

| 단계           | 내용                                                                      | 산출물                                      |
|--------------|-------------------------------------------------------------------------|------------------------------------------|
| 1. 라벨 데이터 구축 | 금융위원회 증권선물위원회 보도자료에서 실명이 확인된 분식회계 확정 기업 수집                              | fraud_labels.csv<br>(18개사)               |
| 2. 재무데이터 수집  | DART Open API로 분식기업 · 정상기업의 실제 재무제표(당기/전기) 조회                           | beneish_scores.csv<br>control_scores.csv |
| 3. 재무비율 계산   | Beneish M-Score의 8개 지표 (DSRI, GMI, AQI, SGI, DEPI, SGAI, LVGI, TATA) 산출 | 8개 재무비율 컬럼                               |
| 4. 데이터 고정    | 분식 11개 + 정상 49개, 총 60개사 데이터를 하나의 학습용 파일로 고정                             | training_data_final.csv                  |
| 5. 모델 학습     | 이상치 처리 -> 스케일링 -> 훈련/검증 분리<br>-> 딥러닝(로지스틱) 모델 학습                        | 학습된 예측 모델                                |
| 6. 실전 적용     | 새 회사의 corp_code+연도 입력<br>-> DART 자동조회 -> 비율계산 -> 확률출력                   | 분식 확률(%)                                 |

## 1-3. 최종 데이터 구성

| 구분             | 표본 수 | 비고                           |
|----------------|------|------------------------------|
| 분식기업 (label=1) | 11개사 | 검찰고발, 대표이사 해임권고 등 확정 조치 사례   |
| 정상기업 (label=0) | 76개사 | 중소형 상장사 49개 + 대기업 27개(추가 보강) |
| 합계             | 87개사 | training_data_final.csv      |

## 2. 데이터 수집 과정

본 절에서는 코드 세부사항이 아니라, 어떤 정보원에서 어떤 방식으로 분식기업 · 정상기업 데이터를 확보했는지 그 과정을 설명합니다.

### 2-1. 분식회계 확정 기업 리스트 확보

가장 먼저 시도한 금융감독원의 '회계감리 지적사례'는 회사명이 A사, B사 등으로 익명 처리되어 있어 활용할 수 없었습니다. 한국거래소의 '불성실공시법인 지정' 자료는 회사 실명이 공개되지만, 대부분 공시 지연 등 절차상 문제이지 실제 회계분식과는 성격이 달라 제외했습니다.

최종적으로 활용한 소스는 금융위원회 산하 증권선물위원회(증선위)가 발표하는 보도자료입니다. 보도자료는 이미 대외 공표를 전제로 하므로 회사 실명이 그대로 명시되며, '회계처리기준을 위반하여 재무제표를 작성 · 공시한 ○○ 등 N개사'라는 형식으로 위반 내용, 위반 회계연도, 조치 수준(과징금 · 감사인지정 · 대표이사 해임권고 · 검찰고발 등)까지 상세히 공개됩니다. 관련 뉴스 검색을 반복하여 총 20개 기업의 실명 리스트를 확보했습니다.

### 2-2. 회사명과 재무데이터 연결

DART(전자공시시스템)는 회사를 이름이 아닌 고유번호(corp\_code)로 관리합니다. 이에 따라 뉴스에서 확인한 회사명을 DART 등록명과 대조하는 작업을 거쳤습니다. 이 과정에서 사명이 변경된 사례(예: 'DI동일' → DART 등록명 '디아이동일'), 동일한 이름을 가진 서로 다른 법인이 다수 존재하는 사례 (한창, 영풍 등, 상장 여부로 구분)를 확인 · 보정하여 최종 18개 기업으로 확정했습니다.

### 2-3. 실제 재무데이터 확보

DART Open API에 회사의 corp\_code와 회계연도를 요청하면 매출액, 매출채권, 자산총계 등 재무제표 항목을 받아올 수 있습니다. 18개 기업 각각에 대해 위반이 발생한 회계연도의 재무제표를 조회했으며, 이 중 카카오톡 · 명가유럽 등 3개사는 비상장이거나 정기 사업보고서 제출 의무가 없어 데이터를 확보하지 못해 제외되었습니다. 최종적으로 8개 재무비율 계산까지 완료된 기업은 11개사입니다.

### 2-4. 정상기업(비교집단) 표본 추출

정상기업은 무작위 추출 방식으로 구성했습니다. DART에 등록된 전체 법인(상장 · 비상장 포함 약 11만 개, 이 중 상장기업은 약 4천 개) 목록에서, 분식기업과 동일한 연도대에 해당하며 분식기업 리스트에 포함되지 않은 기업을 무작위로 추출했습니다. 재무제표 구조가 크게 다른 금융업(은행 · 보험 · 증권 등)은 제외했습니다. 1차로 분식기업 1개사당 3개사씩 추출했으나 표본이 충분하지 않아, 2차로 6개사씩 추가 추출하여 표본을 확장했습니다. 이렇게 추출된 후보 중 실제 DART 데이터 확보에 성공한 49개사를 1차 정상기업 표본으로 사용했습니다.

### 2-5. 대기업 표본 보강

삼성전자 · 현대자동차 등 실제 우량 대기업을 모델에 입력했을 때 예측 확률이 기대보다 높게 나오는 현상을 확인했습니다. 원인을 분석한 결과, 1차 정상기업 표본이 중소형 상장사 위주로 구성되어 초대형 복합기업의 재무비율 스케일과 괴리가 있음을 확인했습니다. 이에 시가총액 상위 대기업 30개(향후 검증에 사용할 삼성전자 · 현대자동차 · SK하이닉스 3개사는 의도적으로 제외)를 정상기업 표본에 추가로 포함했으며, 이 중 27개사의 데이터 확보에 성공하여 최종 정상기업 표본을 76개사로 확장했습니다.

### 2-6. 데이터 수집 과정 요약도

| 구분 | 정보원 | 확보 규모 |
|----|-----|-------|
|----|-----|-------|

|                   |                      |                |
|-------------------|----------------------|----------------|
| 분식기업 후보           | 증선위 보도자료 (뉴스 검색)     | 20개사           |
| corp_code 매칭 후 확정 | DART 등록명 대조 · 보정     | 18개사           |
| 재무데이터 확보 성공       | DART Open API 조회     | 11개사 (최종 사용)   |
| 정상기업 후보 추출(1차)    | DART 전체 법인 목록 무작위 추출 | 66개사 (11개사×6배) |
| 재무데이터 확보 성공(1차)   | DART Open API 조회     | 49개사           |
| 대기업 후보 추출(2차)     | 시가총액 상위 대기업 30개 선정   | 27개사 확보        |
| 최종 정상기업 표본        | 1차 + 2차 합산           | 76개사 (최종 사용)   |

### 3. 사용된 재무비율 (Beneish M-Score 8개 지표)

본 모델은 회계학자 Messod Beneish가 1999년 제안한 분식회계 탐지 지표 8개를 피처(feature)로 사용합니다. 각 지표는 당기와 전기 재무제표를 비교하여 계산됩니다.

| 지표   | 명칭        | 의미                    | 값이 클수록               |
|------|-----------|-----------------------|----------------------|
| DSRI | 매출채권 지수   | 매출채권/매출액 비율의 전기 대비 변화 | 가공매출 의심              |
| GMI  | 매출총이익률 지수 | 전기 매출총이익률 / 당기 매출총이익률 | 수익성 악화 은폐 의심         |
| AQI  | 자산의 질 지수  | 비유동 · 비상각성 자산 비중의 변화  | 자산 부풀리기 의심           |
| SGI  | 매출성장률 지수  | 당기매출 / 전기매출           | 급격한 성장 -> 압박 심화      |
| DEPI | 감가상각률 지수  | 감가상각 속도의 변화           | 이익 부풀리기 의심           |
| SGAI | 판관비율 지수   | 판매비와관리비/매출액 비율의 변화    | 비효율/이상 신호            |
| LVGI | 레버리지 지수   | 부채비율(부채/자산)의 변화       | 재무구조 악화, 분식 유인 증가    |
| TATA | 총발생액 비율   | (운전자본 변화-감가상각비)/총자산   | 실제 현금흐름과 괴리, 이익조정 의심 |

참고: 원래 Beneish M - Score는 위 8개 지표에 고정된 가중치를 곱해 하나의 점수(M)를 산출하고, - 1.78이라는 고정 임계값으로 위험 여부를 판정하는 방식입니다. 그러나 이 고정 공식은 1999년 미국 GAAP/Compustat 데이터를 기반으로 만들어져, 국내 K - IFRS 데이터에 그대로 적용할 경우 탐지력이 떨어지는 한계가 확인되었습니다. 이에 본 프로젝트에서는 8개 지표는 그대로 활용하되, 가중치는 고정하지 않고 실제 국내 분식 · 정상 기업 데이터로 직접 재학습하는 방식(로지스틱 회귀)을 택했습니다.

## 4. 노트북 항목별 상세 설명

(최종\_분식회계예측모델.ipynb)

---

### 1. 라이브러리 불러오기

pandas(데이터 처리), sklearn(전처리/평가), tensorflow · keras(딥러닝 모델)을 불러옵니다.  
tf.random.set\_seed(1)은 모델 학습 결과가 실행할 때마다 달라지지 않도록 난수를 고정하는 역할입니다.

---

### 2. 데이터 불러오기

고정된 학습 데이터(training\_data\_final.csv)를 pandas 데이터프레임으로 읽어옵니다. 이 파일 하나에 분식기업 11개, 정상기업 49개의 재무비율과 정답(label)이 모두 들어있습니다. head()로 상위 5개 행을, info()로 컬럼별 데이터 타입과 결측 여부를 확인합니다.

---

### 3. 데이터 분석 (라벨 분포 확인)

seaborn의 countplot으로 정상(0)기업과 분식(1)기업의 개수를 시각적으로 비교합니다. 두 클래스의 개수 차이(49 vs 11)가 큰 것을 '클래스 불균형'이라 하며, 이는 이후 모델 학습 시 class\_weight 등으로 보정이 필요한 부분입니다.

---

### 4. 이상치 처리

각 재무비율 지표의 상위 1%, 하위 1%에 해당하는 극단값을 해당 경계값으로 눌러주는 클리핑(clipping)을 적용합니다. 예를 들어 특정 기업의 매출총이익률 변화(GMI)가 비정상적으로 크게 튀는 경우, 그 값이 모델 학습을 왜곡하지 않도록 상한선으로 조정합니다. 행을 삭제하는 대신 값만 보정하므로 표본이 적은 상황에서 데이터 손실을 최소화할 수 있습니다.

---

### 5. 결측치 확인

8개 재무비율 컬럼에 비어있는(NaN) 값이 있는지 최종 점검합니다. training\_data\_final.csv는 이미 결측치가 제거된 상태로 고정했기 때문에, 이 단계에서는 0이 출력되는 것이 정상입니다.

---

### 6. 훈련/검증 데이터셋 분리

전체 60개사 데이터를 80%(훈련용)와 20%(검증용)로 무작위 분리합니다. 훈련 데이터로 모델을 학습시키고, 검증 데이터로는 모델이 한 번도 보지 못한 데이터에 대해 얼마나 잘 예측하는지 평가합니다. stratify=y 옵션으로 분식/정상 비율이 훈련 · 검증 세트에 고르게 유지되도록 했습니다.

---

### 7. 스케일링 (RobustScaler)

8개 지표는 단위와 값의 범위가 서로 다릅니다(예: TATA는 -0.2~0.1대, GMI는 1 근처). 이 상태로 모델을 학습하면 값의 범위가 큰 지표가 부당하게 큰 영향력을 갖게 됩니다. RobustScaler는 평균/표준편차 대신

중앙값과 IQR(사분위범위)을 기준으로 값을 조정하기 때문에, 이상치의 영향을 적게 받으면서 모든 지표를 비슷한 스케일로 맞춰줍니다. 훈련 데이터에만 `fit_transform`을 적용하고, 검증 데이터에는 `transform`만 적용하는 것이 중요합니다 (검증 데이터의 정보가 학습 과정에 유출되는 것을 방지).

---

## 8. 딥러닝 모델 구성

Keras의 Sequential 모델로 3개의 은닉층(32 - 16 유닛)을 가진 신경망을 구성했습니다. 은닉층의 활성화 함수는 `relu`, 마지막 출력층은 `sigmoid`를 사용해 0~1 사이의 확률값이 나오도록 했습니다. Dropout(0.2)은 학습 과정에서 일부 뉴런을 무작위로 꺼서 과적합(overfitting)을 방지하는 장치입니다. EarlyStopping은 검증 손실(`val_loss`)이 9번의 epoch 동안 개선되지 않으면 학습을 자동으로 중단시켜, 불필요한 과적합을 막아줍니다.

---

## 9. 학습 곡선 시각화

epoch(학습 반복 횟수)이 늘어남에 따라 훈련 손실(loss)과 검증 손실(`val_loss`)이 어떻게 변하는지 그래프로 확인합니다. 두 곡선이 함께 감소하면 정상 학습, 훈련 손실은 계속 줄어드는데 검증 손실이 다시 올라가면 과적합의 신호입니다.

---

## 10. 모델 성능 평가

학습이 끝난 모델로 검증 데이터를 예측하고, `classification_report`로 정밀도(precision), 재현율(recall), F1 - score를 확인합니다. 분식(1) 클래스에 대한 재현율이 특히 중요한데, 이는 '실제 분식기업을 분식으로 정확히 잡아내는 비율'을 의미하기 때문입니다.

---

## 11. 새 감사대상회사 재무제표 자동 조회 -> 비율 계산 -> 확률 예측

이 모델의 실전 활용 단계입니다. 감사대상회사의 DART corp\_code와 회계연도만 입력하면 DART Open API를 통해 해당 회사의 실제 재무제표(당기 · 전기)를 자동으로 조회하고, 그 원본 데이터로부터 8개 Beneish 지표를 자동 계산합니다. 계산된 지표를 학습 때 사용한 것과 동일한 RobustScaler로 변환한 뒤, 학습된 모델에 입력하여 최종적으로 분식회계 확률(%)을 출력합니다.

## 5. 모델 결과 및 해석

### 5-1. 성능 지표 (검증 데이터셋 기준)

최종 모델은 87개 표본을 80:20으로 분리하여 학습·검증했습니다(검증 표본 약 17~18개, 그중 분식기업 2~3개). 검증 표본 자체가 작아 실행할 때마다 정확도·F1-Score가 다소 변동하는 것을 확인했으며, 대표적으로 관찰된 결과는 아래와 같습니다.

| 지표               | 결과값                   | 의미                                  |
|------------------|-----------------------|-------------------------------------|
| 표본 수             | 87개 (분식 11 / 정상 76)   | 대기업 표본 보강 후 최종 규모                   |
| 정확도(Accuracy)    | 약 80~89%              | 실행마다 변동 (검증 표본이 작아 편차 존재)           |
| F1-Score(분식 클래스) | 약 0.4~0.6             | class_weight 조정 전에는 0에 수렴(전부 정상 예측) |
| 혼동행렬 대표 사례       | 정상 9/16 정답, 분식 2/2 전답 | 재현율 우선(분식 누락 최소화) 경향 확인             |

### 5-2. 지표 해석 및 모델 해석 가능성의 한계

최종 모델은 딥러닝(다층 신경망) 기반으로, 로지스틱 회귀와 달리 지표별 영향력을 계수(coefficient) 형태로 직접 확인하기 어렵다는 한계가 있습니다. 개발 초기 단계에서 로지스틱 회귀로 탐색했을 때는 TATA(총발생액 비율)와 LVGI(레버리지 지수)가 상대적으로 큰 영향력을 보였는데, 이는 회계학적으로도 설명 가능한 결과입니다. TATA가 높다는 것은 실제 현금흐름과 회계상 이익 사이의 괴리가 크다는 신호이고, LVGI가 높다는 것은 부채비율이 급증해 재무구조가 악화되었다는 신호로, 두 지표 모두 분식회계의 전형적인 유인 요인으로 알려져 있습니다. 다만 최종 채택한 딥러닝 모델에서는 이러한 개별 지표의 기여도를 직접 제시하기 어려우며, 이는 실무 도입 시 감사인에게 '왜 이런 확률이 나왔는지'를 설명하기 어렵다는 실질적 한계로 이어집니다.

### 5-3. 한계점

- 표본 크기: 분식기업 표본이 11개로 적어, 통계적 일반화에는 한계가 있습니다. 검증 표본이 17~18개에 불과해 정확도·F1-Score가 실행마다 변동하는 재현성 문제도 함께 확인되었습니다.
- 데이터 접근성: 카카오모빌리티 등 일부 확정 분식기업은 비상장 또는 사업보고서 미제출 대상이라 DART API로 재무데이터를 확보하지 못해 최종 표본에서 제외되었습니다.
- 감가상각비 결측: 국내 재무제표 공시 특성상 감가상각비가 현금흐름표에만 기재되는 경우가 많아, 일부 기업은 DEPI 지표를 중립값(1.0)으로 대체하여 계산했습니다.
- 인과관계 아님: 본 모델은 상관관계 기반의 통계적 예측이며, 특정 재무비율이 분식을 '유발'한다는 인과관계를 증명하는 것은 아닙니다. 실제 감사 판단의 참고 자료로만 활용되어야 합니다.

### 5-4. 향후 개선 방향

- 분식기업 및 정상기업 표본을 지속적으로 확대하여 통계적 신뢰도를 높인다.
- 산업군, 기업 규모 등을 통제 변수로 추가하여 비교집단의 적합성을 높인다.
- 로지스틱 회귀 외에 랜덤포레스트, XGBoost 등 다른 모델과 성능을 비교한다.
- 국내 데이터에 맞는 임계값(threshold) 재보정을 통해 실무 적용 가능성을 높인다.

## 6. 실전 테스트 사례

학습에 사용되지 않은(out - of - sample) 실제 기업 3곳을 모델에 입력하여 확률을 확인했습니다. 우량기업 2곳과, 학습 데이터에 포함되지 않은 별도의 분식회계 확정 기업 1곳을 비교 대상으로 선정했습니다.

| 회사              | 실제 상태         | 예측 확률 | 비고                         |
|-----------------|---------------|-------|----------------------------|
| 삼성전자            | 정상(우량기업)      | 12.9% | 학습 데이터 미포함                 |
| 현대자동차           | 정상(우량기업)      | 9.9%  | 학습 데이터 미포함                 |
| 빙그레             | 정상(중견기업)      | 13.6% | 학습 데이터 미포함                 |
| SOOP (구 아프리카TV) | 분식회계 확정 (중과실) | 32.3% | 학습 데이터 미포함, 2025년 증선위 조치   |
| SK하이닉스          | 정상(우량기업)      | 34.9% | 학습 데이터 미포함, 2022년 업황 급락 반영 |

### 6-1. SOOP 사례 및 개발 과정에서의 추가 발견

SOOP(옛 아프리카TV, 종목코드 067160)은 2025년 증선위로부터 게임 콘텐츠 광고 매출을 대리인임에도 총액으로 인식하여 매출을 부풀린 사실로 과징금 및 감사인 지정 3년 조치를 받은 확정 사례입니다. 본 모델에 2022년(위반 금액이 가장 컸던 해, 약 270억원) 재무비율을 입력한 결과 32.3%의 확률을 보였는데, 이는 명확히 정상인 삼성전자 · 현대자동차 · 빙그레(9.9~13.6%)보다는 높은 수준입니다.

다만 개발 과정에서 SK하이닉스(정상기업)가 SOOP과 근접하거나 이를 상회하는 확률(34.9%)을 보이는 현상이 반복적으로 관찰되었습니다. 원인을 추적한 결과 두 가지가 확인되었습니다. 첫째, SK하이닉스의 2022년 재무제표는 반도체 업황 급락기를 반영하여 매출총이익률(GMI)과 판관비율(SGAI) 등이 실제로 크게 악화된 시기였으며, 이는 재무적 곤경과 분식 유인을 완전히 구분하지 못하는 Beneish 지표 체계 자체의 한계와 맞닿아 있습니다. 둘째, 노트북 셀을 순서대로 완전히 재실행하지 않고 일부만 재실행할 경우 난수 시드 고정(tf.random.set\_seed)이 의도대로 작동하지 않아 실행할 때마다 결과가 달라지는 재현성 문제가 발견되었습니다. 이후 커널을 완전히 재시작하여 전체 셀을 처음부터 순서대로 실행하는 방식으로 재현성을 확보했습니다.

### 6-2. 클래스 불균형 대응 과정

정상기업 표본에 대기업 27개사를 추가하면서 정상 대 분식 비율이 약 7:1까지 벌어졌고, 이로 인해 가중치 보정 없이 학습한 모델은 모든 표본을 '정상'으로만 예측하는 현상(F1 - Score=0)이 나타났습니다. 이에 class\_weight를 도입하여 분식 클래스에 더 큰 가중치를 부여했으며, 가중치를 원래 비율 그대로 적용했을 때는 오탐이 과도해지는 반대 현상이 나타나 최종적으로 원래 비율의 50%(WEIGHT\_STRENGTH=0.5) 수준으로 완화하여 정확도와 재현율의 균형을 맞추었습니다. 또한 예측 안정성을 높이기 위해 여러 모델을 반복 학습하여 평균을 내는 앙상블 기법을 시도했으나, 표본 규모(87개)에서는 오히려 개별 모델 간 예측 편차가 컸던 SK하이닉스 사례에서 안정성 개선 효과가 뚜렷하지 않아, 최종적으로는 단일 모델 방식으로 확정했습니다.

### 6-3. 종합 해석

세 가지로 요약됩니다. 첫째, 명확히 건전한 기업(삼성전자, 현대자동차, 빙그레)은 모두 10%대 초반의 낮은 확률로 일관되게 판정되어, 모델이 뚜렷한 정상 패턴은 안정적으로 인식함을 확인했습니다. 둘째, 확정 분식기업(SOOP)은 이들보다 높은 32.3%로 산출되어 방향성 있는 변별력을 보였습니다. 셋째, 재무적 으로 특이한 시기를 지난 우량기업(SK하이닉스)은 확정 분식기업과 근접한 확률을 보이며 모델의 한계를 드러냈는데, 이는 표본 규모의 한계이자 Beneish 지표 체계 자체가 '재무적 곤경'과 '분식 의도'를 완전히 구분하지 못한다는 학계의 지적과도 일치하는 결과입니다.

## 7. 한 줄 요약

---

본 프로젝트는 국내 확정 분식회계 기업 11개사와 정상기업 76개사(중소형 상장사 49개 + 대기업 27개)의 실제 재무제표 데이터를 DART Open API로 직접 수집하고, Beneish M - Score의 8개 재무비율을 계산한 뒤, 이를 딥러닝(다층 신경망) 모델로 학습시켜 '감사대상회사의 재무정보를 입력하면 분식회계 확률을 출력하는' 예측 모델을 구현한 것입니다. 개발 과정에서 클래스 불균형으로 인한 예측 편향, 소규모 표본에서의 재현성 문제, 앙상블 기법의 한계 등을 순차적으로 발견하고 대응하였으며, 최종 모델은 명확히 건전한 기업을 10%대 초반의 낮은 확률로, 확정 분식기업을 그보다 높은 확률로 판별하는 방향성 있는 변별력을 보였습니다. 다만 재무적으로 특이한 시기를 지낸 기업에 대해서는 여전히 판단이 불안정한 한계를 보였으며, 이는 표본 규모의 한계이자 향후 개선 과제로 확인되었습니다.

---

본 보고서는 AICE - Associate 학습 내용을 실전 회계 데이터 분석에 적용해본 개인 프로젝트 기록입니다.